

## Part B: - Calculation Exercises.

Ex 1: - Count Vector:

Corpus:  $D_1 = \text{"cat dog cat eats fish"}$

$D_2 = \text{"dog eats fish"}$

$D_3 = \text{"cat likes fish"}$

Vocab: [cat, dog, eats, fish, likes].

$\Rightarrow$  Count vector của  $D_1$  là  $v_1 = [1, 1, 1, 1, 0]$

$D_2$   $v_2 = [0, 1, 1, 1, 0]$

$D_3$   $v_3 = [1, 0, 0, 1, 1]$

Ex 2: - TF: Tính TF của  $D_1$ :

$$- tf(\text{cat}, D_1) = \frac{1}{3}$$

$$- tf(\text{eats}, D_1) = \frac{1}{3}$$

$$- tf(\text{fish}, D_1) = \frac{1}{3}$$

$$\left. \begin{array}{l} - tf(\text{cat}, D_1) = \frac{1}{3} \\ - tf(\text{eats}, D_1) = \frac{1}{3} \\ - tf(\text{fish}, D_1) = \frac{1}{3} \end{array} \right\} \text{ kiểm tra lại: } \sum tf(t, D_1) = \frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1 \text{ (đúng)}$$

Ex 3: - IDF: Tính IDF

$$\left\{ \begin{array}{l} N = 3 \\ df(\text{cat}) = 2 \\ df(\text{dog}) = 1 \end{array} \right.$$

$$df(\text{eats}) = 2$$

$$df(\text{fish}) = 3$$

$$df(\text{likes}) = 1$$

$$\Rightarrow idf(\text{cat}) = \log \frac{3}{2} = \ln\left(\frac{3}{2}\right) \approx 0,4055$$

$$idf(\text{dog}) = \ln\left(\frac{3}{1}\right) \approx 1,0986$$

$$idf(\text{eats}) = \ln\left(\frac{3}{2}\right) \approx 0,4055$$

$$idf(\text{fish}) = \ln\left(\frac{3}{3}\right) = 0$$

$$idf(\text{likes}) = \ln\left(\frac{3}{1}\right) = 1,0986$$

term có IDF thấp nhất là fish, bởi vì "fish" đều có ở tất cả text trong corpus

Exercise 4: Tính tfidf của D-1.

D-1 = "cat eats, fish":

$$\begin{aligned} \text{tfidf}(\text{cat}, D-1) &= \text{tf}(\text{cat}, D-1) \times \text{idf}(\text{cat}) \\ &= \frac{1}{3} \cdot 0,4055 = 0,1352 \end{aligned}$$

$$\begin{aligned} \text{tfidf}(\text{eats}, D-1) &= \text{tf}(\text{eats}, D-1) \times \text{idf}(\text{eats}) \\ &= \frac{1}{3} \cdot 0,4055 = 0,1352 \end{aligned}$$

$$\begin{aligned} \text{tfidf}(\text{fish}, D-1) &= \text{tf}(\text{fish}, D-1) \times \text{idf}(\text{fish}) \\ &= \frac{1}{3} \cdot 0 = 0 \end{aligned}$$

TF-IDF của fish = 0 dù xuất hiện ở mọi document là do TFIDF ~~không~~ có tính đến quan trọng là mỗi từ xuất hiện trong tất cả các document không giúp phân biệt document này với document khác.

Exercise 5: Cosine Similarity:

$$x = [1, 1, 1]$$

$$y = [1, 1, 0]$$

$$\cos(x, y)$$

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \|y\|} = \frac{2}{\sqrt{3} \sqrt{2}} = \frac{2}{\sqrt{6}} \approx 0,8165$$

- Cosine similarity không bằng  $\frac{2}{3}$  là do cosine similarity không đo hệ số tương quan mà đo góc giữa 2 vector

## Exercise 6. Du lịch

1. Document nào có similarity cao nhất?

- D<sub>1</sub>

2. \_\_\_\_\_ thấp nhất?

- D<sub>3</sub>

3. Term nào có thi' có giá trị IDF thấp?

medical, image do xuất hiện ở nhiều văn bản

4. Chỉ sử dụng Count Vector thì có thay đổi?

## Part C: Prediction Before

Prediction 1: 30k documents ~ 30k unique terms.

Prediction 2: Sparsity  $\rightarrow$  TFIDF matrix sẽ sparse.

Tỷ lệ zero  $\approx 99\%$  ở giá trị

1 doc có khoảng 100 term unique.

Prediction 3: - Search  $\rightarrow$  không nhất thiết do TFIDF chủ yếu dựa trên lexical matching chứ chưa đi sâu vào semantic.